¿Va a llover este año?

Índice de sequía para cada celda de Centroamérica, calculado en CPU y en GPU

Javier España (23361) · Angel Esquit (23221) · José Mérida (201105)
CC3069 Computación Paralela y Distribuida · Universidad del Valle de Guatemala · Caso 4

Don Chepe tiene una sola cosecha

- Familias de Zacapa, Chiquimula, Jutiapa y otros departamentos viven de **una cosecha** de maíz y frijol al año.
- Si la lluvia falla y nadie avisa a tiempo, no hay semilla resistente ni cambio de siembra, y llega la **inseguridad alimentaria**.
- El MAGA necesita saber **qué municipios alertar** esta temporada.

horas o días

Si calcular el índice de lluvia de toda la región tarda eso, la alerta llega cuando la cosecha ya se perdió.

Don Chepe es un personaje ilustrativo.

Los datos

- **ERA5** de Copernicus, lluvia horaria, rejilla de 0,25° (unos 31 km), licencia CC-BY 4.0.
- Ventana de Centroamérica, 49 × 65 = 3185 celdas, bajada de la copia pública ARCO-ERA5.
- Limpieza de cada mes. Se revisa la forma del archivo, se cuentan NaN (0), se recortan 1 342 169 negativos por redondeo y se marcan valores sospechosos (0).
- Se descartan 5 archivos que no enlazan con la serie continua.

28.0 M

valores horarios en 12 meses (112 MB en float32)

3185

celdas, cada una con 366 días de lluvia y su propio ajuste

Qué es el SPI

- Es un **número por cada celda** del mapa que dice si la lluvia reciente es mucha o poca para ese lugar.
- Compara contra lo **normal de la misma celda**. 50 mm son poca lluvia en una zona húmeda y mucha en una seca.
- El **0** es normal y cada paso negativo es más seco. Cuando baja de **−1** se activa la alerta.

Sequía extrema	Sequía moderada	Normal	Más húmedo
menor que −2	−2 a −1	−1 a 1	mayor que 1

Cómo lo calculamos paso a paso

PASO 1

Lluvia diaria

Se suman las 24 horas de cada día y se pasa a milímetros. Son 366 días por celda.

PASO 2

Acumulado móvil

Suma de los últimos k = 30 y 90 días con una suma prefija (scan). Cada ventana cuesta una resta.

PASO 3

Gamma por celda

Con las ventanas de cada celda se estiman la forma α y la escala β (aproximación de Thom) y la fracción q de ventanas sin lluvia.

PASO 4

Puntaje z

Se ve qué tan rara es cada ventana en su celda y se convierte a una normal estándar.

$$z = \Phi^{-1}(q + (1 - q) \cdot G(x ; \alpha, \beta))$$

- **z < −1** es sequía moderada y **z < −2** es sequía extrema. Hay 337 ventanas de 30 días en cada una de las 3185 celdas.

Qué se paraleliza y qué no

Etapa	Cómo trabaja la GPU	CPU (ms)	GPU (ms)	Speedup
Lluvia horaria a diaria	Una suma por celda y día, todas a la vez	4.2	0.4	**10.1×**
Acumulado móvil (scan)	Suma prefija sobre el tiempo, una columna por celda	2.1	0.1	**17.9×**
Gamma, CDF y puntaje z	Un hilo por celda y ventana, sin comunicación	127.6	32.8	**3.9×**
Días secos consecutivos	Depende del día anterior, secuencial en el tiempo	1.9	5.6	**0.3×**

- Las celdas son independientes y están contiguas en memoria, así que los hilos vecinos leen direcciones vecinas.
- La última etapa es **más lenta en GPU**, porque lanza un kernel por paso de tiempo y casi no hay trabajo que repartir.

Cómo medimos para comparar justo

- La misma función corre en CPU y en GPU, solo cambia el módulo numérico (NumPy y SciPy contra CuPy).
- Mismos datos, misma tarea y NVIDIA GeForce RTX 4070 SUPER con CUDA 12.9.
- Mediana de 5 repeticiones, calentamiento de la GPU y **synchronize** antes de parar el reloj.
- Tres tiempos por separado, lectura de disco, copia host a GPU y cómputo.

1.4e-03

diferencia máxima del SPI entre CPU y GPU

7.0e-03

error medio contra el ajuste de máxima verosimilitud de SciPy, en 10 celdas de Guatemala

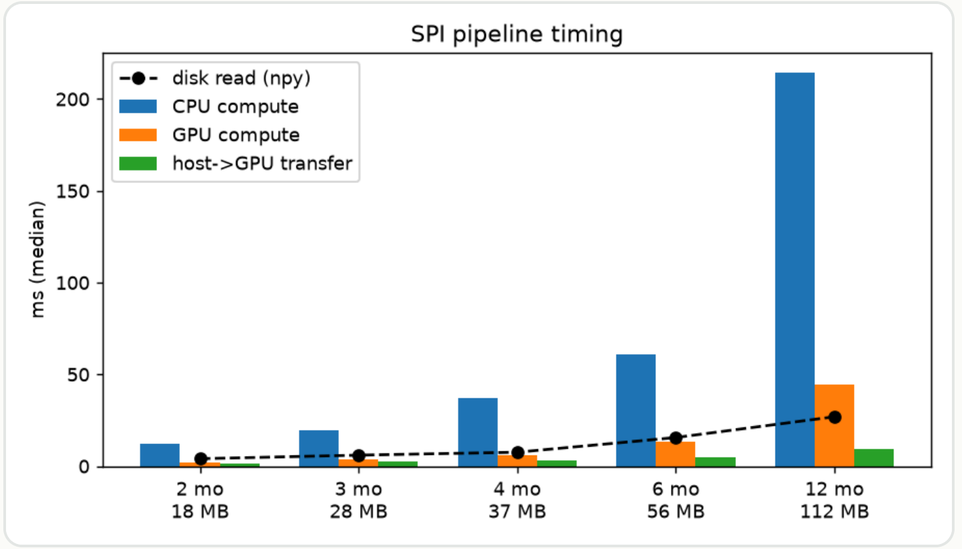
El resultado, GPU contra CPU

4.8×

speedup del cálculo, de 214.3 ms en CPU a 44.5 ms en GPU

17%

del tiempo de GPU se va en copiar los datos (9.3 ms)



Mover datos pesa casi tanto como calcular

45%

del tiempo del flujo en GPU se va en leer del disco y copiar a la GPU

3.0×

speedup del flujo completo, contra 4.8× del cálculo solo

- Según Amdahl, la parte paralela (f = 98.6 %) sí se acelera, pero la lectura no y la copia es un costo extra de la GPU.
- Aun con cálculo gratis, el flujo completo no pasaría de **6.7×**.
- Con 10 veces más celdas el speedup se mantiene (3.9×), así que la relación CPU y GPU no cambia con el tamaño.

Del benchmark al problema real

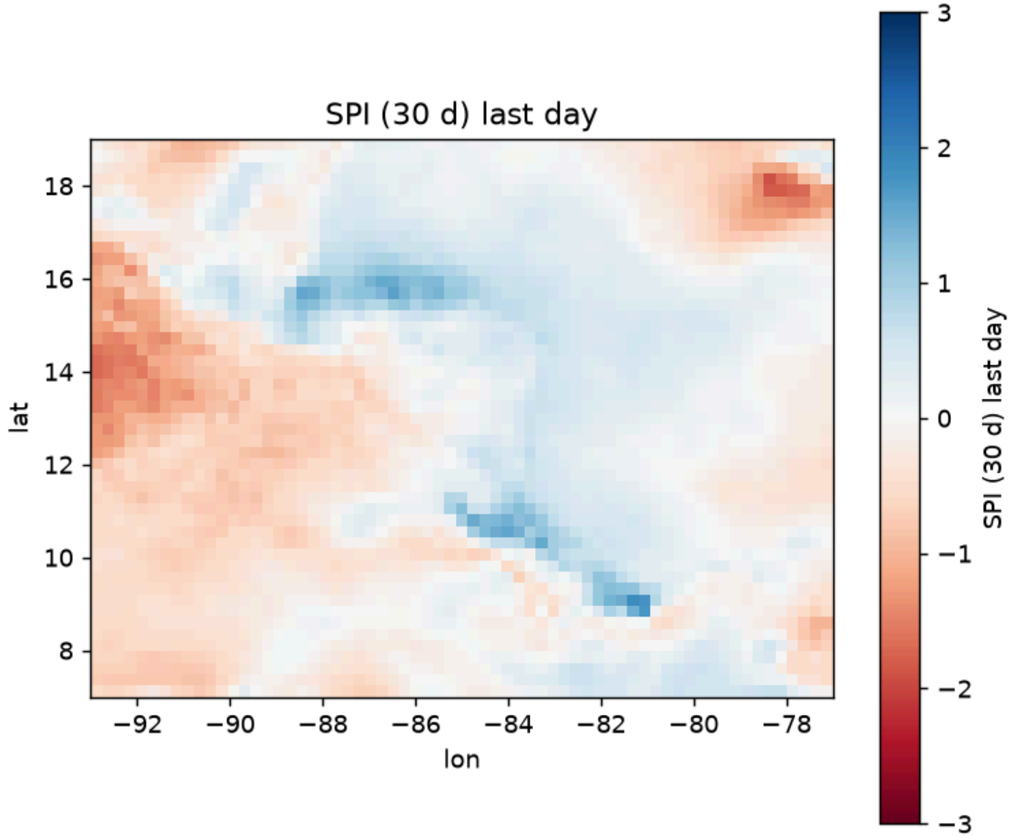
El MAGA necesita actualizar el mapa cuando llegan datos y probar otras definiciones de sequía. Así de largo sería una actualización completa.

	Escenario	GB	CPU	GPU
A	12 meses, 0,25°, 2 escalas (medido)	0.1	0.24 s	**0.08 s**
B	40 años, 0,25°, 2 escalas	4.5	10 s	**3 s**
C	40 años, 0,1° (ERA5-Land), 2 escalas	28.0	60 s	**20 s**
D	como C con 12 escalas (1 a 12 meses)	28.0	6.0 min	**2.0 min**

- Son estimaciones lineales a partir de lo que medimos, no mediciones nuevas.
- La GPU acorta el trabajo unas 3.0 veces. En el escenario D son **6.0 min contra 2.0 min**, la diferencia entre esperar y poder iterar.

Qué cambia para el MAGA

- Con los datos ya en memoria, el mapa de SPI de toda la región se **recalcula en una fracción de segundo** y se prueban definiciones de sequía al instante.
- La prioridad es la **logística de datos**, con series particionadas por espacio o subconjuntos del CDS, antes de comprar más GPU.
- Con solo 12 meses estos mapas no son hallazgos de sequía. Falta validar contra años secos y agregar por municipio.



Fuentes

Hersbach, H. et al. (2023), *ERA5 hourly data on single levels from 1940 to present*, C3S CDS, doi:10.24381/cds.adbb2d47 (CC-BY 4.0).

Copia ARCO-ERA5 (Google Cloud Public Datasets), github.com/google-research/arco-era5.

McKee, Doesken y Kleist (1993), *The relationship of drought frequency and duration to time scales*.

NumPy, SciPy, xarray, Zarr, CuPy y Matplotlib. NVIDIA CUDA, docs.nvidia.com/cuda

Código en github.com/TonitoMC/cuda-challenge-2