Informe final. Sequía en el Corredor Seco con GPU

Caso 4, Agricultura y clima · CC3069 Computación Paralela y Distribuida, Sección 20 · Universidad del Valle de Guatemala · 11 de noviembre de 2026

Javier Eduardo España Pacheco (23361) · Angel Esteban Esquit Hernández (23221) · José Antonio Mérida Castejón (201105)

1 Problema e impacto esperado

Las familias campesinas del Corredor Seco (Zacapa, Chiquimula, El Progreso, Jalapa, Jutiapa y Baja Verapaz) dependen de una sola cosecha de maíz y frijol al año. El MAGA necesita avisarles antes de que la sequía arruine la cosecha, para que puedan sembrar semilla resistente, mover la fecha de siembra o pedir ayuda alimentaria. Si calcular el índice de lluvia de toda la región tarda horas o días, la alerta llega tarde. Si tarda segundos, se puede recalcular con cada dato nuevo y probar distintas definiciones de sequía.

2 Datos, tamaño, limpieza y preparación

Fuente. Reanálisis ERA5 de Copernicus (C3S), *ERA5 hourly data on single levels*, variable `total_precipitation` (metros de agua por hora), rejilla de 0,25° (unos 31 km). Cita: Hersbach et al. (2023), doi:10.24381/cds.adbb2d47. Licencia **CC-BY 4.0**. Los datos se bajaron de la copia pública ARCO-ERA5 de Google Cloud (`gs://gcp-public-data-arco-era5`), que no pide cuenta y contiene el mismo reanálisis en formato Zarr. La ventana va de 7 a 19°N y de 93 a 77°O, es decir Centroamérica, con $49 \times 65 = 3185$ celdas.

Tamaño. Usamos 12 meses de datos horarios (8 784 horas), que son **28.0 millones de valores** (112 MB en `float32`). Supera el mínimo de 10 millones de registros, pero no llega a 1 GB ni a los 40 años de la propuesta. El almacén guarda un archivo por cada hora del planeta completo, así que bajar un mes toma cerca de un minuto y bajar décadas no cabía en el tiempo del proyecto. Una extrapolación lineal da unos 1.12 mil millones de valores (4.5 GB) para 40 años, pero es una estimación y no una medición.

Limpieza (`scripts/01b_clean.py`, resultados en `results/cleaning_report.json`). Para cada mes se revisa que el archivo tenga las horas esperadas (días del mes por 24) y la rejilla de 49×65. Se cuentan los valores NaN o infinitos (0), se recortan a cero los negativos que ERA5 deja por redondeo de la acumulación, del orden de -10^{-8} m (1 342 169 valores), y se marcan los valores físicamente sospechosos, mayores a 200 mm por hora (0). Quedaron 12 meses aceptados y 5 archivos descartados, porque los meses de enero a mayo de 2023 no enlazan con 2024 y una laguna en la serie estropearía los acumulados móviles. El script conserva solo la racha continua más larga de meses.

3 Qué calculamos exactamente

Calculamos el Índice Estándar de Precipitación (SPI, McKee et al. 1993) para cada una de las 3185 celdas. El SPI responde a una pregunta simple. *¿La lluvia acumulada en los últimos k días, comparada con lo que es normal en esta celda, es mucha o poca?* Los pasos son los siguientes.

1. **Lluvia diaria.** Con la lluvia horaria $P[t, c]$ (celda c, hora t) sumamos cada bloque de 24 horas y pasamos a milímetros, $D[d, c] = 1000 \sum_{h \in d} P[h, c]$. Hay 366 días.
2. **Acumulado móvil.** Para una escala de k días, $S_k[d, c] = \sum_{j=d-k+1}^{d} D[j, c]$. Se calcula con una suma prefija (*scan*), $C[d] = \sum_{j<d} D[j, c]$ y $S_k[d, c] = C[d + k] - C[d]$, de modo que cada ventana cuesta una resta. Usamos $k = 30$ y $k = 90$ días, que equivalen a SPI de 1 y 3 meses, y dan 337 y 277 ventanas por celda.
3. **Ajuste de una distribución gamma por celda.** Para cada celda tomamos las ventanas con lluvia ($x > 0$), calculamos su media $\bar{x}$ y la media de sus logaritmos, y con $A = \ln \bar{x} - \overline{\ln x}$ estimamos la forma y la escala con la aproximación cerrada de Thom, $\alpha = \dfrac{1 + \sqrt{1 + 4A/3}}{4A}$ y $\beta = \bar{x}/\alpha$. También guardamos q, la fracción de ventanas con lluvia cero.
4. **Conversión a puntaje z.** Para cada ventana, $H(x) = q + (1 - q)\, G(x; \alpha, \beta)$, donde G es la gamma incompleta regularizada, y el SPI es $z = \Phi^{-1}(H(x))$, con Φ^{-1} la inversa de la normal estándar. Un valor de 0 es una ventana normal, $z < -1$ es sequía moderada y $z < -2$ es sequía extrema.
5. **Reducciones.** Para Guatemala (caja de 13,7 a 17,8°N y de 92,2 a 88,2°O, 272 celdas) calculamos la fracción de celdas con $z < -1$ el último día. Además calculamos, por celda, el máximo de días secos consecutivos (menos de 1 mm), que es una recurrencia secuencial en el tiempo.

Qué es paralelo. Cada celda se ajusta y se convierte sin necesitar a las demás, y las escalas son independientes entre sí. Guardamos los datos como una matriz de días por celdas, con las celdas en el eje contiguo, de modo que los

hilos vecinos de la GPU leen direcciones vecinas de memoria (accesos coalescidos). El *scan* es paralelo sobre el eje del tiempo. Lo único secuencial es el conteo de días secos consecutivos.

Qué simplificamos. El SPI estándar ajusta una gamma distinta para cada mes del calendario, lo que exige muchos años. Con 12 meses ajustamos una sola gamma por celda con todas sus ventanas. También usamos la aproximación de Thom en lugar de máxima verosimilitud iterativa.

4 Implementación en CPU y en GPU

La misma función recibe como argumento el módulo numérico, `numpy` o `cupy`, y ejecuta las mismas operaciones sobre los mismos datos. En CPU usamos NumPy y SciPy (`gammainc`, `ndtri`). En GPU usamos CuPy y `cupyx.scipy.special` sobre una NVIDIA GeForce RTX 4070 SUPER (CUDA 12.9), en la computadora local. Para medir, cada configuración se repite 5 veces y se reporta la mediana, la GPU se calienta antes de medir y se llama a `synchronize()` antes de detener el reloj. Se separan tres tiempos, lectura de disco, copia de la memoria del host a la GPU y cómputo.

5 Mediciones

Meses	Valores (M)	Disco (ms)	CPU (ms)	H→D (ms)	GPU (ms)	Speedup cómputo	Speedup copia+cómputo	máx $\lvert\Delta\text{SPI}\rvert$
2	4.6	4.1	12.1	1.3	2.1	5.8×	3.5×	8.6e-04
3	7.0	6.0	19.6	2.3	3.6	5.4×	3.3×	6.0e-04
4	9.2	7.6	37.0	3.0	6.1	6.1×	4.0×	1.0e-02
6	13.9	15.6	61.1	4.6	13.4	4.6×	3.1×	1.1e-03
12	28.0	26.9	214.3	9.3	44.5	4.8×	3.9×	1.4e-03

Cuadro 1: Tiempos medianos para SPI de 30 y 90 días. Disco es la lectura de archivos `.npy` con caché caliente, así que es un valor optimista. Speedup es T_{CPU}/T_{GPU}.

Con los 12 meses, $T_{CPU} = 214.3$ ms y $T_{GPU} = 44.5$ ms de cómputo más 9.3 ms de copia. El speedup es **4.8**× solo del cómputo y 3.9× al incluir la copia, que equivale al 17 % del tiempo de cómputo en GPU. **Validación.** La diferencia máxima del SPI entre CPU y GPU es 1.4e-03. Contra el ajuste de máxima verosimilitud de `scipy.stats.gamma.fit` en 10 celdas de Guatemala, el error medio es 7.0e-03 unidades de SPI. Con una rejilla 9 veces mayor (los mismos datos replicados, solo para medir tiempos, 252 M valores), la CPU tarda 1.96 s y la GPU 0.51 s, un speedup de 3.9×.

Etapa (todos los meses)	CPU (ms)	GPU (ms)	Speedup
daily sum	4.2	0.4	10.1×
scan	2.1	0.1	17.9×
gamma fit cdf z	127.6	32.8	3.9×
dry days loop(secuencial)	1.9	5.6	0.3×

Cuadro 2: Desglose por etapa. La etapa secuencial en el tiempo es más lenta en GPU.

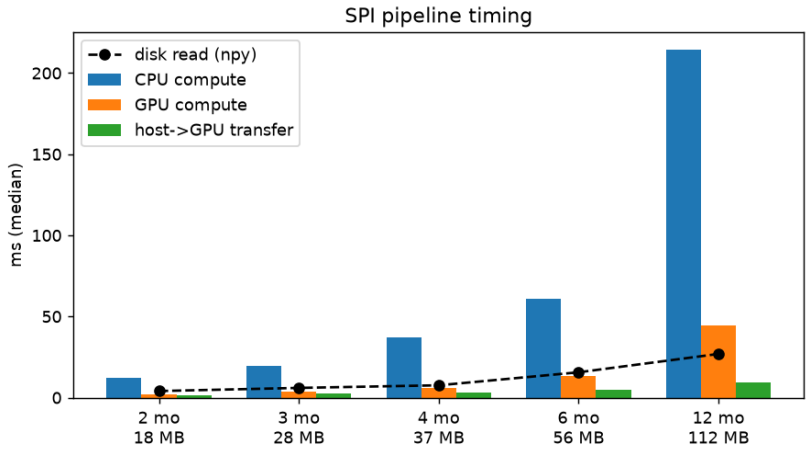


Figura 1: Tiempos por tamaño de datos, en ms.

6 Análisis. Cuello de botella, Amdahl y 10 veces más datos

El cómputo no es el cuello de botella, traer los datos sí. Descargar los 12 meses tomó unos 836 s (14 min), alrededor de 3 902 veces el cómputo en CPU (214.3 ms). Leer del disco local cuesta el 13 % del cómputo en CPU y la copia a la GPU el 17 % del tiempo de GPU.

Ley de Amdahl. La fracción paralelizable del cómputo, todo salvo el conteo de días secos, es $f = 98.6\,\%$ del tiempo en CPU. Si las partes paralelas se aceleran S_p veces, el speedup total es $S = 1/((1-f) + f/S_p)$. Con una GPU infinitamente rápida el límite sería $1/(1-f) \approx 72\times$. Con el $S_p = 3.5\times$ que medimos en las etapas, Amdahl predice $3.4\times$, lo que coincide con lo observado. Pero el flujo completo (descarga, lectura y cómputo) mejora apenas $1.0002\times$, porque la descarga es la parte serial que la GPU no toca. El conteo de días secos tarda 1.9 ms en CPU y 5.6 ms en GPU, porque el ciclo lanza un *kernel* por paso de tiempo y la latencia de lanzamiento supera al trabajo.

Por qué el speedup es modesto. Es de 4 a 6 veces y no de 100. El problema es chico (millones de valores y no miles de millones), cada celda hace poca aritmética por byte leído y las funciones especiales (`gammainc`, `ndtri`) pesan más que las sumas. Con 10 veces más datos todas las etapas escalan casi linealmente. La prueba sintética de 9 veces más celdas mantiene el speedup en $3.9\times$, así que el speedup del cómputo no cambia, pero el tiempo de descarga también crece 10 veces. Para 40 años ($\approx$4.5 GB), una estimación lineal da 8.6 s de cómputo en CPU y 2.2 s en GPU, así que mover datos seguiría mandando. La GPU gana importancia cuando los datos ya están en memoria y se recalculan muchas variantes (otros umbrales, escalas o regiones).

7 Resultado e impacto para la industria

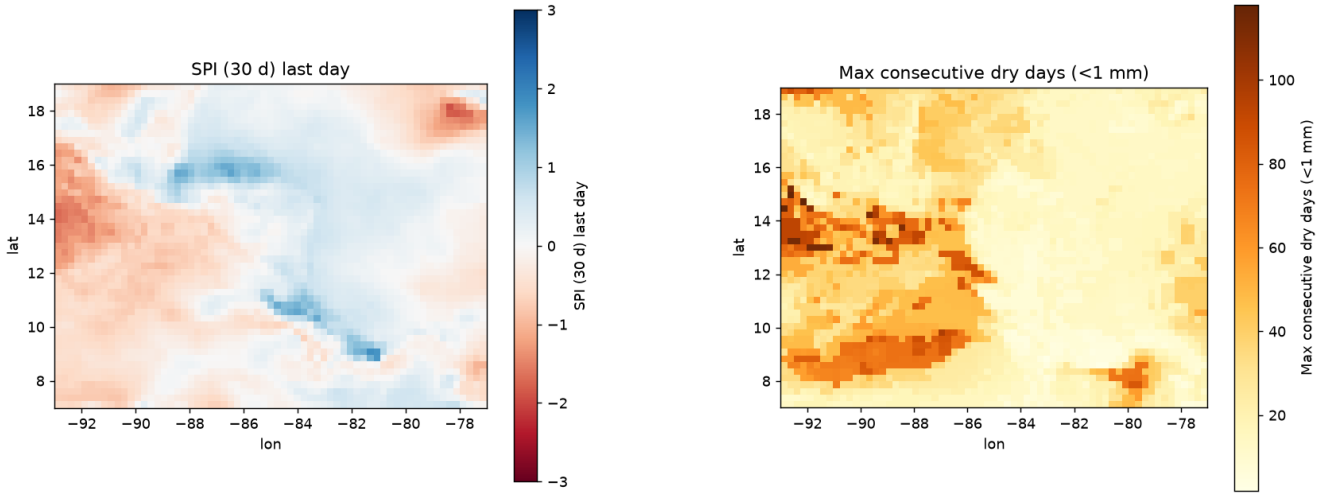


Figura 2: A la izquierda el SPI de 30 días el último día de la serie, a la derecha el máximo de días secos consecutivos.

Con los datos ya en memoria, el mapa de SPI de toda Centroamérica se recalcula en milisegundos, así que el MAGA puede cambiar la definición de sequía y ver el mapa al instante. SPI-30d: 11 % de las celdas de Guatemala bajo -1 el último día (media -0.20). SPI-90d: 0 % de las celdas de Guatemala bajo -1 el último día (media $+0.25$). El máximo medio de días secos consecutivos en Guatemala es 31. Estas cifras no deben leerse como hallazgos de sequía, porque con tan pocos meses el ajuste gamma no es representativo. Lo que sí respalda la medición es una recomendación operativa. Conviene invertir primero en la logística de datos (guardar las series con partición espacial o pedir subconjuntos regionales al servidor del CDS) y después en más GPU.

8 Límites

- Solo 12 meses. No se midió el escalamiento por años ni Guatemala contra Centroamérica, y la prueba de 10 veces es sintética.
- Una gamma por celda sobre todas sus ventanas (no una por mes del calendario), aproximación de Thom, escalas de 30 y 90 días y sin SPI de 6 meses.
- Sin agregación municipal, porque no tenemos el shapefile, y sin validación contra años secos documentados, que requiere series largas.
- Lectura de disco con caché caliente. ERA5 es un reanálisis de 0,25° y no son mediciones de estación.

9 Reproducibilidad, uso de IA y fuentes

Código. https://github.com/TonitoMC/cuda-challenge-2. Pasos, en orden, dentro de un entorno virtual con `numpy scipy xarray "zarr>=3"gcsfs cupy-cuda12x matplotlib pandas`. Se ejecutan `scripts/01_download.py <años>`, `01b_clean.py`, `02_spi_benchmark.py`, `03_plots.py` y `04_amdahl.py` (ver `README.md`). Se necesita una GPU NVIDIA con CUDA 12.

Uso de IA. El código y el borrador de este informe se hicieron con ayuda de Claude Code (Anthropic). Los integrantes revisaron los resultados y pueden explicar cada parte.

Fuentes. Hersbach, H. et al. (2023), *ERA5 hourly data on single levels from 1940 to present*, C3S CDS, doi:10.24381/cds.adbb2d47 (CC-BY 4.0). Copia ARCO-ERA5, Google Research y Cloud Public Datasets, https://github.com/google-research/arco-era5. McKee, Doesken y Kleist (1993), *The relationship of drought frequency and duration to time scales*. Librerías NumPy, SciPy, xarray, Zarr, CuPy, Matplotlib y pandas, y la documentación de NVIDIA CUDA, https://docs.nvidia.com/cuda/.